

Week 10 MapReduce & Hadoop 學習指引

章節大綱 (Outline)	學習指引 (Study Guide)
What is big data?	學習 Hadoop 的首要任務是理解它試圖解決的問題：大數據帶來的巨大挑戰。請詳細複習大數據的核心特徵，也就是著名的 3V：資料量龐大 (Volume)、生成與處理速度極快 (Velocity)，以及資料結構多樣化 (Variety)，包含了大量非結構化或半結構化的資料。您必須清楚釐清，傳統的關聯式資料庫 (RDBMS) 在面對這類海量且缺乏固定 Schema 的資料時，會遭遇嚴重的效能瓶頸與擴展限制，這正是業界急需全新分散式運算與儲存架構的根本原因。
MapReduce	MapReduce 是處理巨量資料的核心程式設計模型，其設計哲學深受「分而治之 (Divide and Conquer)」概念的影響。您需要深刻理解兩個階段的明確分工：Map 階段負責在各個資料節點上就近進行資料過濾、轉換與提取，並產出 Key-Value 對；Reduce 階段則負責將這些中間結果進行跨節點的彙總與整合。此外，請務必掌握系統層面的運作邏輯，包括 JobTracker 如何進行全域的任務排程與資源分配，以及 TaskTracker 如何在各個節點上監控並執行具體的 Map 或 Reduce 任務。
Meet Hadoop	認識 Hadoop 這個由 Apache 基金會維護的重量級開源框架。請複習它的發展起源以及核心設計目標：Hadoop 專為在由商用廉價硬體 (Commodity hardware) 所組成的龐大叢集上運行而生。您的學習重點在於理解 Hadoop 如何「化劣勢為優勢」，也就是它並不強求底層硬體具備高可靠性，而是透過軟體架構層面 (如資料多重副本與任務自動重試) 提供卓越的容錯機制 (Fault Tolerance)。這使得企業能以極低的硬體成本，獲得具備強大橫向擴展能力的大數據處理平台。
Hadoop	HDFS 是支撐整個 Hadoop 生態系的儲存骨幹，專為儲存超大

章節大綱 (Outline)	學習指引 (Study Guide)
Distributed File System	檔案而設計。請深入探討其「一次寫入，多次讀取 (write-once, read-many)」的串流存取設計理念。您需要熟練掌握 HDFS 的核心架構：預設 64MB (或 128MB) 的資料區塊 (Block) 設計有何優勢？Namenode (Master 節點) 如何負責管理整個檔案系統的 Metadata (如檔案名稱、權限與區塊映射表)？而 Datanode (Slave 節點) 又是如何負責實際儲存資料區塊並定期發送心跳訊號 (Heartbeat)？理解這些節點間的互動是掌握分散式儲存的關鍵。
How to install Hadoop	任何雲端與大數據的理論都必須透過實際動手做來驗證。本節要求您具備從零開始建置 Hadoop 偽分散式 (Pseudo-distributed) 叢集的能力。請複習所有關鍵的前置作業：包含在虛擬機 (VM) 中安裝 Linux 系統、正確配置 Java 執行環境，以及設定 SSH 無密碼登入機制。接著，您需要熟悉 Hadoop 的核心 XML 設定檔 (core-site.xml, hdfs-site.xml 等) 的配置意義。最後，請務必親自執行格式化 Namenode 的指令，並透過經典的 Wordcount 範例，體驗完整的任務提交、執行與結果檢視流程。